


De buscar palabras a buscar significado

Archivos tradicionales, bases vectoriales (RAG) y el lugar que ocupan en un agente de IA


En la sesión 4, el filtro de palabras dejó fuera una noticia sobre normativa del agua en los edificios, porque no decía «vivienda» en ningún sitio, aunque afectaba al parque de viviendas. Esa es la diferencia entre **buscar lo que está escrito** y **buscar lo que quiere decir**. Este documento resume en tres páginas cómo funciona lo segundo, qué riesgos tiene y dónde encaja cuando se construye un agente.

1 Dos formas de buscar

Un **sistema de archivos tradicional** (carpetas, nombres de fichero y una búsqueda por coincidencia de palabras) encuentra lo que **nombras**. Una **base vectorial** guarda además el **significado** de cada fragmento y encuentra lo que **quiere decir lo mismo**, aunque use otras palabras.



Esquema ilustrativo: las posiciones no son datos reales. Aquí el «mapa» es plano para poder verlo; el siguiente esquema lo muestra como es de verdad.



Esquema ilustrativo en tres dimensiones (los datos no son reales). Los ejes no tienen un nombre concreto: solo sirven para situar cada fragmento. Los grupos por tema aparecen solos, sin que nadie los defina, y la zona de resultados es una esfera, no un círculo. Un modelo real usa cientos de dimensiones, imposibles de dibujar, pero funciona igual.

2 Cómo funciona una base vectorial, en cuatro pasos

1 · Trocear

Cada documento se divide en fragmentos (párrafos o bloques de texto). Un documento no es un punto, son varios.

2 · Convertir

Cada fragmento se convierte en una lista de números que representa su significado. Se llama *embedding*.

3 · Colocar

Los fragmentos con significado parecido quedan cerca unos de otros, como puntos en el espacio.

4 · Buscar

Tu pregunta se convierte en números del mismo modo y se recuperan los fragmentos más cercanos.


Los metadatos son los «apellidos» del documento. Son columnas que se añaden a cada uno: tema, ámbito (estatal, autonómico, local), fecha, si trata de AVRA o no. Sirven de dos maneras: **te dicen de qué trata cada documento sin abrirlo**, y **permiten a la búsqueda filtrar y priorizar** (por ejemplo, dar preferencia a los que llevan el apellido «Andalucía»). Los metadatos pueden rellenarse a mano o proponerlos una IA y que una persona los revise.

FRAGMENTO	ÁMBITO	TEMA	RESULTADO
A · Decreto autonómico de vivienda protegida	Andalucía	Normativa	Sí
B · Ley estatal sobre alquiler	España	Normativa	No: otro ámbito
C · Orden autonómica de eficiencia en edificios	Andalucía	Normativa	Sí
D · Ayudas municipales a la rehabilitación	Otra CCAA	Financiación	No: ámbito y tema

Ejemplo ilustrativo, sin noticias reales. Pregunta: «normativa de Andalucía». Con las columnas de metadatos ámbito y tema, como las de la sesión 5, la búsqueda combina el significado con un filtro y prioriza A y C.

3 RAG: cómo se usa con una IA


RAG son las siglas en inglés de *generación aumentada por recuperación*. Un modelo de IA, por sí solo, responde con lo que aprendió al entrenarse. Con RAG, antes de responder **primero busca en tus documentos** y solo entonces redacta la respuesta apoyándose en lo que ha encontrado. Así contesta sobre **tu** material, sin tener que leerlo entero cada vez.



El paso 4 «debería» citar la fuente si se le pide. Que la cite no garantiza que sea correcta: por eso la comprobación humana sigue siendo necesaria.

4 Dónde encaja en un agente

Un agente de IA se describe con cuatro piezas, y son las mismas en Copilot, Gemini, ChatGPT o Claude, aunque cada herramienta las llame de una manera. La búsqueda por significado es una forma habitual de resolver una de ellas: el **conocimiento**.



Las instrucciones dicen cómo pensar; el conocimiento pone los datos; los metadatos dan criterio a la búsqueda.

Cada herramienta resuelve el conocimiento a su manera y no siempre detalla cómo. Lo que importa para trabajar bien es conocer sus **límites**. Un ejemplo con fecha, tomado de la documentación de Microsoft (septiembre de 2026):

Ejemplo: agentes de Copilot creados con Agent Builder

- Admiten hasta **20 ficheros subidos** desde el equipo y hasta **100 ficheros de SharePoint**.
- Respetan los permisos de cada persona sobre los ficheros de SharePoint. Pero lo que se sube al agente lo puede ver **cualquiera que tenga acceso al agente**.
- La función de SharePoint que rellena metadatos automáticamente **solo procesa ficheros en inglés**.

5 Riesgos, y qué hacer con cada uno

RIESGO	QUÉ HACER
Un fragmento pierde el contexto. Al trocear, una frase puede quedar separada de lo que la aclara.	Pide siempre el fragmento y el documento de donde sale. Léelo entero antes de fiarte.
Parecido no es relevante. Lo cercano en significado puede no ser lo que necesitas, y algo importante puede quedar fuera.	Prueba con preguntas cuya respuesta ya conoces y comprueba si la encuentra.
El modelo puede seguir inventando o interpretando mal el texto que ha recuperado.	Comprueba la cita en el original. Es la supervisión humana de siempre, aplicada a cada respuesta.
Un metadato mal puesto se arrastra. Si una IA clasifica mal, todas las búsquedas posteriores heredan el error.	Pide la justificación de cada clasificación y revisa una muestra. Ejemplo de la sesión 5: una noticia valorada como «positiva» para AVRA sin que AVRA apareciera en el texto.
Información desactualizada. La base es una foto de un momento: si el documento cambia, la base no se entera sola.	Anota cuándo se cargó cada cosa y vuelve a cargar lo que cambie.
Quién ve qué. Lo que se sube a una base o a un agente compartido puede llegar a quien lo use.	No subas documentos internos sensibles ni datos personales a herramientas no autorizadas por tu organización.
Cada herramienta tiene sus límites: número de ficheros, formatos, idiomas.	Pruébala con tus propios documentos antes de darla por buena.

Para llevarte

- Un sistema de archivos encuentra lo que **nombras**; una base vectorial encuentra lo que **significas**.
- RAG es lo que da **conocimiento** a un agente; los metadatos le dan **criterio**.
- Nada sin fuente y nada sin revisión humana: una respuesta que cita un documento sigue teniendo que comprobarse.

Fuentes: Microsoft Learn, «Add knowledge sources to your declarative agent in Microsoft 365 Copilot» (learn.microsoft.com/en-us/microsoft-365/copilot/extensibility/agent-builder-add-knowledge) y «Create autofill columns» (learn.microsoft.com/en-us/sharepoint/copilot-in-sharepoint-create-autofill-columns), consultadas en septiembre de 2026. Las cifras y los límites pueden cambiar.

Material de formación para un grupo concreto. Los esquemas son ilustrativos y no contienen datos reales.